

Python 数据分析实战笔记

从数据清洗到可视化（md-to-pdf 示例文档，用于验证全部语法）

作者：示例作者

版本：v1.2

日期：2025-01-01

本文档为 md-to-pdf 示例，运行 `md-to-pdf example.md` 即可生成 PDF

目录

1	数据读取与清洗	1
1.1	读取 CSV	1
1.2	常用操作对比	1
1.3	数据清洗要点	1
1.4	任务清单示例	2
1.5	引用与脚注	2
1.6	数学符号（正文直写即可）	2
1.7	表情与警示标记（v1.0.6 起）	3
1.8	图片	3
2	可视化与输出	5
2.1	绘图三步法	5
2.2	配置片段	5
2.3	相关资源	5

使用说明

本文演示 md-to-pdf 的全部特性：封面 front matter、LaTeX 自动章节编号、表格、代码块高亮、嵌套/任务列表、引用、脚注、数学公式、要点框、强制分页与图片。数学公式由 LaTeX 原生渲染，无需 KaTeX。

1 数据读取与清洗

1.1 读取 CSV

读取文件用标准库或 pandas 均可，注意编码与缺失值处理。行内的强调包括加粗、斜体、删除线、行内代码 `pd.read_csv`，以及文字中的特殊字符：50% 完成、a_b、C++、{花括号}、# 号、\$ 符号。

```
import pandas as pd

df = pd.read_csv("sales.csv", encoding="utf-8-sig")
df = df.dropna(subset=["amount"])
df["date"] = pd.to_datetime(df["date"])
print(df.head())
```

1.2 常用操作对比

操作	方法	说明	备注
读取	<code>read_csv</code>	读取 CSV 文件	常用
筛选	<code>query</code>	按条件过滤行	高效
分组	<code>groupby</code>	聚合统计	重点
透视	<code>pivot_table</code>	行列重排	进阶

1.3 数据清洗要点

- 缺失值：`dropna` / `fillna` 二选一
 - 直接删除行→样本量损失
 - 均值/中位数填充→引入偏差
- 重复值：`drop_duplicates` 按关键列去重
- 异常值： 3σ 原则或 IQR 方法剔除

按步骤执行：

- 1. 先探查 `df.info()` 与 `df.describe()`
- 2. 再处理缺失与重复
- 3. 最后统一数据类型
- 4. 校验结果写入新文件

1.4 任务清单示例

- ☒ 环境安装与依赖确认
- ☒ 数据读取脚本
- ☐ 清洗规则文档化
- ☐ 自动化流水线

1.5 引用与脚注

数据清洗是整个分析流程中最耗时的一步，通常占全部工作量的 60% 以上。

有人建议把清洗规则写成配置项¹，以便复现与审计。公式示例：质能方程 $E = mc^2$ ，以及更复杂的 $f(x) = \frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ 。

$$S = \sum_{i=1}^n x_i^2, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

1.6 数学符号（正文直写即可）

中文字体缺字形的常用符号已内置回退（v1.0.5 起），正文里直接写即可，不必包 `$...$`：对 $\forall \varepsilon > 0$ 存在 $\exists \delta > 0$ ； $A \subset B \subseteq C$ ； $x \mapsto y$ ； $a \Leftrightarrow b$ ；空集 $\emptyset$ 、偏导 ∂ 、梯度 ∇ 、张量积 $\otimes$ ；角标 10^{-3} 、 m^3 、 v_0 、 a_1 、 x^2+y^2 ； $x \in \mathbb{R}$ 、 $\lceil x \rceil \geq x$ ；✓ 通过 ✗ 未通过。

类别	符号
逻辑 / 集合	$\forall \exists \nexists \notin \ni \not\subset \supsetneq \setminus$
箭头	$\Leftarrow \Rightarrow \Leftrightarrow \mapsto \rightarrow \rightsquigarrow \leftrightarrow \Uparrow$
运算	$\int \int \mp \cdot \circ * \bullet \simeq \cong \ll \gg \ominus \otimes \dots \vdots$
罗马数字 / 图形	I II III IV ■ □ ▲ △ ▼ ▽ ◆ ◇ ○ ◎ ● ★ ☆

¹配置化清洗规则便于团队协作与规则复用。

提示

表里没收录的冷僻符号仍可写成 `\gtrsim` 这样的数学式；确实常用的可以加进 `md_to_pdf.py` 的 `SYMBOL_FALLBACKS`。

1.7 表情与警示标记（v1.0.6 起）

正文里可直接写 `!⚠️`（带变体选择符的 `!⚠️` 效果相同），PDF 里会显示成对应图标。
以标记开头的引用块会自动变成彩色告示框：

思路

先看数据分布，再决定清洗策略；分布严重偏斜时优先考虑中位数。

警告

⚠️ 单位换算最容易出错，务必逐项核对一遍再往下算。

易错提醒

`dropna` 之后索引不连续，取行要用 `iloc` 而不是 `loc`。

1.8 图片




图 1.1: 数据清洗流程图（示例图片）

小提示

`groupby` 之后记得用 `reset_index()` 恢复列结构，避免链式索引警告。

注意事项

`fillna` 默认按列填充，跨列填充需显式传入字典或使用 `axis=1`，否则容易静默出错。

2 可视化与输出

2.1 绘图三步法

1. 确定图形类型（折线/柱状/散点）
2. 精简数据字段（只保留需要的列）
3. 输出与标注（标题、轴标签、图例）

2.2 配置片段

```
{  
  "output": "report.pdf",  
  "dpi": 300,  
  "style": "seaborn-v0_8",  
  "savefig": { "bbox_inches": "tight" }  
}
```

2.3 相关资源

- 官方文档: <https://pandas.pydata.org/docs/>
- 自动链接测试: <https://matplotlib.org/stable/> 与 [Pandas 中文教程](#)

本文档由 *md-to-pdf* 生成, *LaTeX* 风格、紧凑排版、纯色封面。